Lecture 12 - Contents

An overview of the main sections in this lecture.

This outline is for guidance. Navigate the slides with the left/right arrow keys.

Lecture 12:

Knowledge Distillation and Model Compression

Efficient Medical AI: Compression for Clinical Deployment

Model Compression Overview

왜 압축이 필요한가?

- 의료 현장의 제한된 컴퓨팅 리소스 (모바일, 웨어러블, POC 장비)
- 실시간 진단 요구사항 (저지연 추론)
- 배터리 효율성 및 전력 소비 최소화
- 개인정보 보호를 위한 온-디바이스 처리

Compression Pipeline

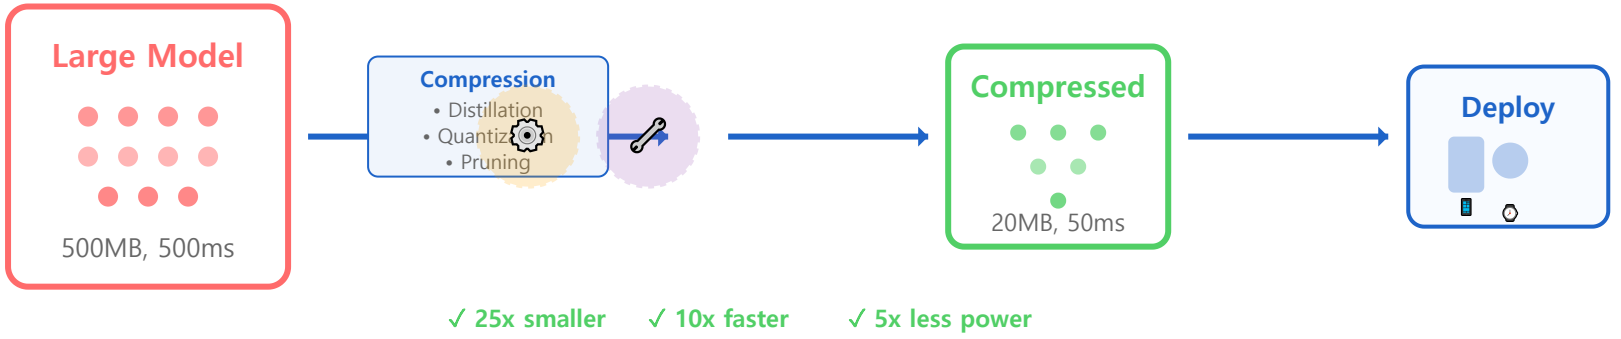

주요 압축 방법론

Knowledge Distillation

Teacher 모델의 지식을 작은 Student 모델로 전달

Quantization

가중치 비트 수 감소 (FP32→INT8)

Pruning

불필요한 가중치 및 뉴런 제거

핵심 트레이드오프: 모델 크기/속도 향상 ↔ 정확도 유지

Part 1/3:

Knowledge Distillation for Medical Models

1. Teacher-Student Framework
2. Soft Target Training
3. Temperature Scaling
4. Feature Distillation
5. Attention Transfer
6. Progressive & Multi-Teacher Distillation

Teacher-Student Framework

🎓 Teacher Model

크기: 대형 (수백만~수십억 파라미터)

성능: 최고 정확도

용도: 지식 제공

예시: ResNet-152, BERT-Large

🎯 Student Model

크기: 소형 (10~100배 작음)

성능: Teacher에 근접

용도: 실제 배포

예시: MobileNet, DistilBERT

Knowledge Transfer

전달되는 지식

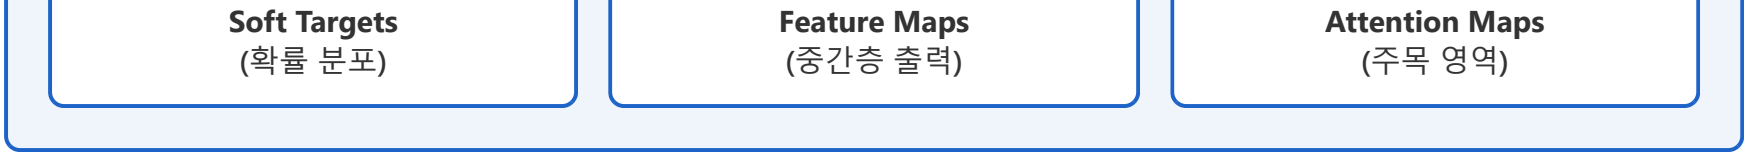
Soft Targets
(확률 분포)
Feature Maps
(중간층 출력)
Attention Maps
(주목 영역)

Soft Target Training

Hard Targets

[0, 0, 1, 0]

One-hot 벡터
정답 클래스만 1

❌ 클래스 간 관계 정보 없음

Soft Targets

[0.05, 0.15, 0.70, 0.10]

확률 분포
모든 클래스에 확률

✅ 클래스 간 유사도 학습

Soft Targets의 장점

✓ 더 풍부한 정보: Teacher가 학습한 클래스 간 관계 전달
✓ 일반화 성능 향상: 과적합 방지
✓ 의료 영상: 질병 간 유사성 정보 활용 (예: 양성/악성 경계 케이스)

Temperature Scaling

Softmax with Temperature

$$p_i = \exp(z_i/T) / \Sigma \exp(z_j/T)$$

T = Temperature 파라미터

T = 1

일반 Softmax

[0.05, 0.10, 0.80, 0.05]

Sharp 분포

T = 3~5

증류에 최적

[0.15, 0.20, 0.45, 0.20]

Soft 분포

T → ∞

극한 케이스

[0.25, 0.25, 0.25, 0.25]

Uniform 분포

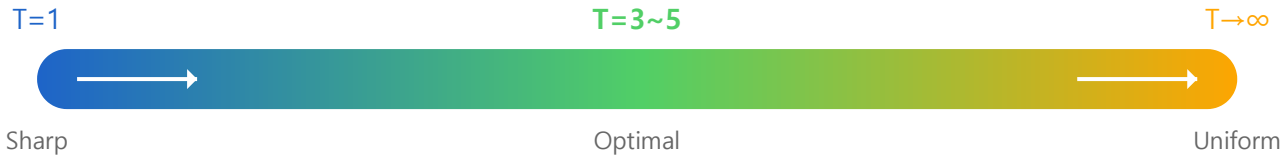

실전 팁: 의료 영상 분류에서 **T=3~4**가 효과적
높은 **T** → 클래스 간 관계 정보 풍부 → **Student** 학습 향상

Feature Distillation

특징 수준 증류 (Feature-Level Distillation)

Teacher와 Student의 중간층(intermediate layers) 출력을 매칭

레이어 매칭 전략

1:1 Matching

Teacher Layer 12 → Student Layer 6

Multiple Matching

여러 레이어 동시 매칭

Adaptive Matching

학습 가능한 변환 사용

Feature Distillation Loss

$$L_{feature} = ||f_T(x) - f_S(x)||^2$$

f_T: Teacher features, f_S: Student features

Attention Transfer

Attention Transfer

Teacher 모델의 attention map을 Student에 전달하여 중요 영역 학습

의료 영상에서의 활용

병변 위치 학습

Teacher가 주목하는 병변 영역을 Student도 학습

X-ray/CT 분석

폐렴, 종양 등 이상 부위 attention 전달

해석 가능성 향상

임상의가 이해 가능한 판단 근거 제공

Attention Transfer Loss

$$L_{AT} = ||A_T - A_S||_2$$

A: Attention maps (spatial activation)

Progressive Distillation

점진적 증류 (Progressive Distillation)

큰 모델에서 작은 모델로 단계적으로 지식 전달

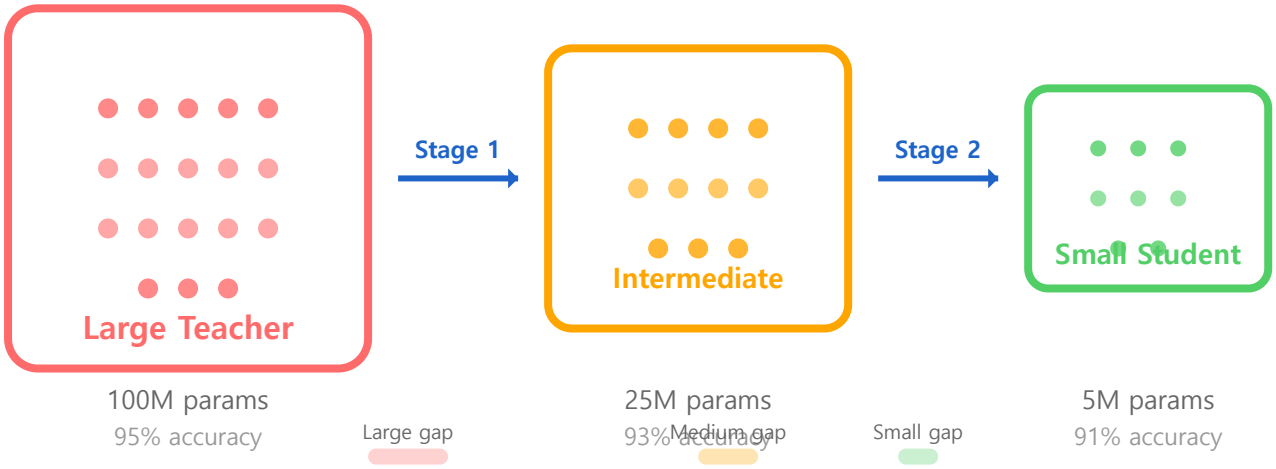

Stage 1

Teacher (Large)

↓

Intermediate Model

(중간 크기)

→

Stage 2

Intermediate Model

↓

Student (Small)

(최종 배포)

장점

✓ Knowledge gap 감소: 큰 차이를 단계별로 줄임

✓ 안정적 학습: 급격한 성능 저하 방지

✓ 다양한 크기 모델 확보: 배포 환경에 맞게 선택

Multi-Teacher Distillation

Multi-Teacher Distillation

여러 Teacher 모델의 앙상블 지식을 Student에 전달

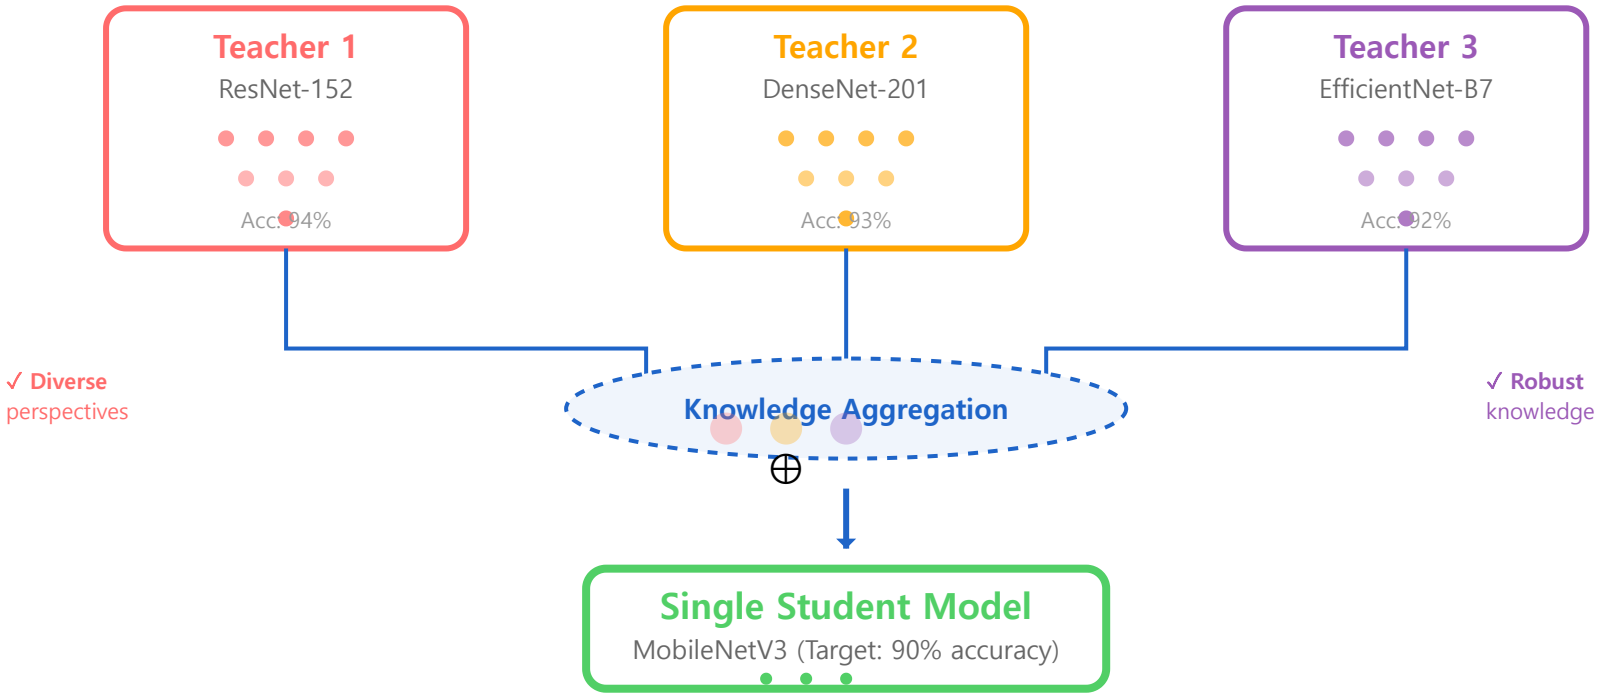

Multiple Teachers

Teacher 1

Teacher 2

Teacher 3

ResNet-152

DenseNet-201

EfficientNet-B7

↓ Knowledge Aggregation ↓

Single Student Model

MobileNetV3

지식 통합 방법

균등 가중

평균 (Average)

차등 가중

가중 평균 (Weighted)

동적 선택

Attention 기반

Part 2/3:

Quantization and Pruning

1. INT8/INT4 Quantization
2. Mixed Precision Strategies
3. Structured Pruning
4. Magnitude Pruning
5. Lottery Ticket Hypothesis
6. Dynamic Sparsity

INT8/INT4 Quantization

정수 양자화 (Integer Quantization)

부동소수점(FP32/FP16)을 정수(INT8/INT4)로 변환하여 모델 크기 감소

비트 수 비교

FP32

32 bits
4 bytes
기본 학습 정밀도

INT8

8 bits
1 byte
75% 메모리 절감

INT4

4 bits
0.5 bytes
87.5% 메모리 절감

양자화의 효과

메모리 사용량 감소

추론 속도 향상

전력 소비 감소

정확도 트레이드오프: INT8은 일반적으로 1% 미만 정확도 감소
INT4는 Quantization-Aware Training 필요

Mixed Precision Strategies

혼합 정밀도 전략

레이어별로 다른 정밀도를 사용하여 성능과 효율성의 균형 달성

전략 예시

입력층

INT8/FP16
빠른 처리 가능

중간층

INT8
대부분의 연산

출력층

FP16/FP32
정확한 확률 계산

레이어 민감도 분석

민감한 레이어 → FP16/FP32 유지

덜 민감한 레이어 → INT8/INT4 적용

도구

PyTorch Quantization, TensorRT, ONNX Runtime

Structured Pruning

구조적 가지치기 (Structured Pruning)

전체 채널, 필터, 또는 레이어를 제거하여 구조적으로 압축

구조적 가지치기 유형

Channel Pruning

[■][■][□][■]
채널 단위 제거

Filter Pruning

Filter 1: ■■■■
Filter 2: □□□□
Filter 3: ■■■■

Layer Pruning

Layer 1 → ■
Layer 2 → □
Layer 3 → ■

구조적 가지치기의 장점

✓ 하드웨어 친화적: 특수 하드웨어 불필요

✓ 실제 속도 향상: dense matrix 연산 유지

✓ 메모리 감소: 실제 파라미터 수 감소

의료 응용: X-ray 분류 모델에서 40% 채널 제거 → 2배 빠른 추론, 정확도 98.5% → 97.8% (1% 미만 감소)

Magnitude Pruning

크기 기반 가지치기 (Magnitude Pruning)

작은 가중치 값을 0으로 만들어 희소성(sparsity) 증가

가지치기 프로세스

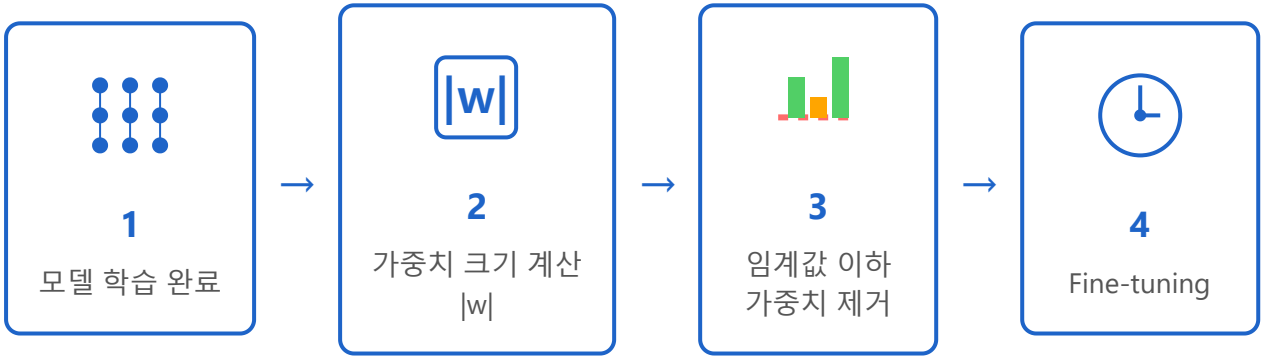

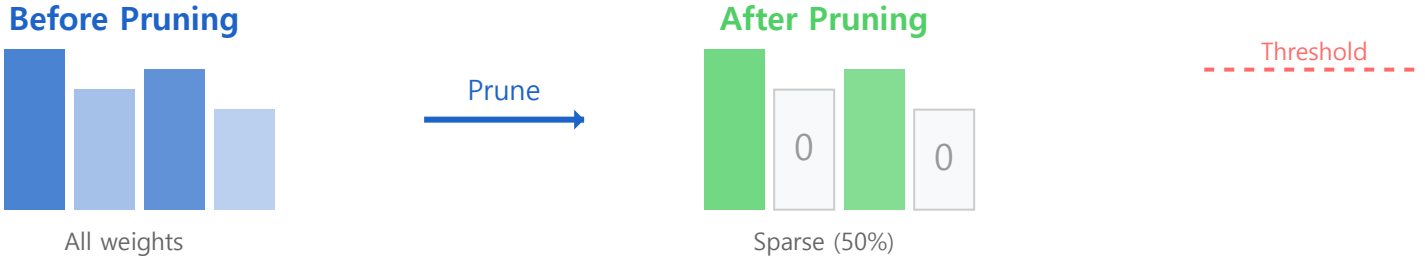

임계값 설정 전략

θ

Global Threshold

전체 네트워크 단일 임계값

θ₁ θ₂ θ₃

Layer-wise Threshold

레이어별 다른 임계값

Top-k

Top-k Pruning

상위 k% 가중치만 유지

희소성 예시

Dense: [0.8, 0.3, -0.5, 0.1, -0.9]

↓ Threshold = 0.4

Sparse: [0.8, 0, -0.5, 0, -0.9]

40% 희소성 달성

Lottery Ticket Hypothesis

복권 티켓 가설 (Lottery Ticket Hypothesis)

큰 네트워크에는 처음부터 학습해도 좋은 성능을 내는
작은 서브네트워크("winning ticket")가 존재한다

Winning Ticket 찾기

① **무작위 초기화** 네트워크를 무작위로 초기화

↓

② **학습** 전체 네트워크를 학습

↓

③ **가지치기** 중요하지 않은 가중치 제거

↓

④ **재초기화** 원래 초기값으로 되돌림

↓

⑤ **재학습** 서브네트워크만 학습 (Winning Ticket!)

Network Evolution

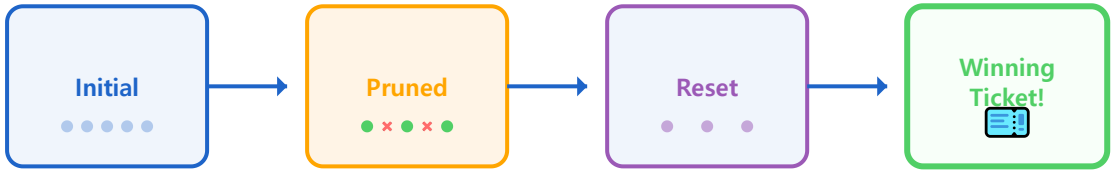

주요 발견

- 10-20%의 가중치만으로도 원래 성능 달성 가능
- 학습 속도도 빨라짐
- 초기화 방법이 매우 중요

Dynamic Sparsity

동적 희소성 (Dynamic Sparsity)

학습 중 가지치기 패턴을 동적으로 조정하여 최적 희소 구조 탐색

정적 vs 동적 희소성

Static Sparsity

- 한 번 가지치기 → 고정
- 간단하지만 비최적
- 성능 제한적

Dynamic Sparsity

- 학습 중 지속적 재구성
- 복잡하지만 최적화
- 더 나은 성능

동적 가지치기 방법

RigL

Random Sparse Training
주기적으로 가중치 grow/prune

SET

Sparse Evolutionary Training
진화 알고리즘 기반

DST

Dynamic Sparse Training
gradient 기반 재구성

장점: 학습 초기부터 희소성 유지 → 학습 비용 감소
최종 희소 구조가 더 효율적

Part 3/3:

Edge Deployment in Healthcare

1. Mobile Health Apps & Wearable Devices
2. Point-of-Care Systems
3. Latency & Battery Optimization
4. Model Serving on Edge
5. Performance-Size Tradeoffs
6. Case Studies & Hands-on

Mobile Health Apps

모바일 헬스 애플리케이션

스마트폰에서 실행되는 의료 AI 모델의 최적화 및 배포

모바일 제약 조건

메모리

2-8 GB RAM
모델 크기 제한

연산

제한된 FLOPS
CPU/NPU 활용

배터리

전력 소비 최소화
장시간 사용

최적화 전략

- ✓ 모델 크기 < 50MB (이상적으로 < 20MB)
- ✓ INT8 양자화 필수
- ✓ MobileNet, EfficientNet 아키텍처 활용
- ✓ TensorFlow Lite, Core ML 변환

의료 응용 사례

피부 병변 분류

당뇨병성 망막병증 스크리닝

심전도(ECG) 분석

Wearable Device Models

웨어러블 디바이스 AI

스마트워치, 피트니스 트래커 등 초소형 디바이스에서의 실시간 AI 처리

웨어러블 디바이스 사양

Apple Watch

- RAM: 1GB
- CPU: 저전력
- 배터리: 18시간

Fitbit

- RAM: < 512MB
- 매우 제한적
- 배터리: 5-7일

극한의 모델 요구사항

모델 크기:	< 5MB (이상적: < 1MB)
추론 시간:	< 100ms (실시간 처리)
정밀도:	INT8 또는 INT4
배치 크기:	1 (단일 샘플)

웨어러블 의료 응용

심박수 이상 탐지

수면 패턴 분석

낙상 감지

부정맥 모니터링

Point-of-Care Systems

POC (Point-of-Care) 진단 시스템

환자 곁에서 즉시 수행하는 진단을 위한 휴대용 AI 장비

POC 시스템 예시

휴대용 초음파

- Butterfly iQ, Lumify
- 실시간 영상 분석
- 병변 자동 탐지

혈액 분석기

- 즉석 혈액 검사
- AI 기반 결과 해석
- 응급실, 외래 활용

망막 카메라

- 당뇨망막병증 스크리닝
- 오프라인 동작
- 개발도상국 활용

POC 시스템 요구사항

🎯 **정확도 최우선:** 의료 기기 수준 (95%+)

⚡ **빠른 응답:** 5-30초 이내 결과

🔌 **오프라인 동작:** 네트워크 불필요

🛡️ **개인정보 보호:** 데이터 외부 전송 없음

배포 고려사항: FDA/CE 인증 필요, 임상 검증 필수,
의료진 교육 및 사용자 인터페이스 중요

Latency Optimization

지연시간 최적화 (Latency Optimization)

실시간 의료 응용을 위한 추론 속도 향상 기법

Inference Latency Breakdown

지연시간 구성 요소

데이터 전처리
이미지 리사이징, 정규화
5-20ms

모델 추론
가장 큰 비중
50-500ms

후처리
결과 해석, 시각화
5-10ms

최적화 기법

모델 압축

- Quantization
- Pruning
- Distillation

2-10x 속도 향상

추론 엔진

- TensorRT
- ONNX Runtime
- TFLite

1.5-3x 속도 향상

하드웨어 가속

- GPU
- NPU/TPU
- FPGA

5-100x 속도 향상

실시간 처리 기준

Soft Real-time

< 100ms

일반 진단 보조

Hard Real-time

< 10ms

수술 로봇, 응급 시스템

Battery Efficiency

배터리 효율성 최적화

모바일/웨어러블 디바이스의 장시간 사용을 위한 전력 소비 최소화

모델 실행 시 전력 소비

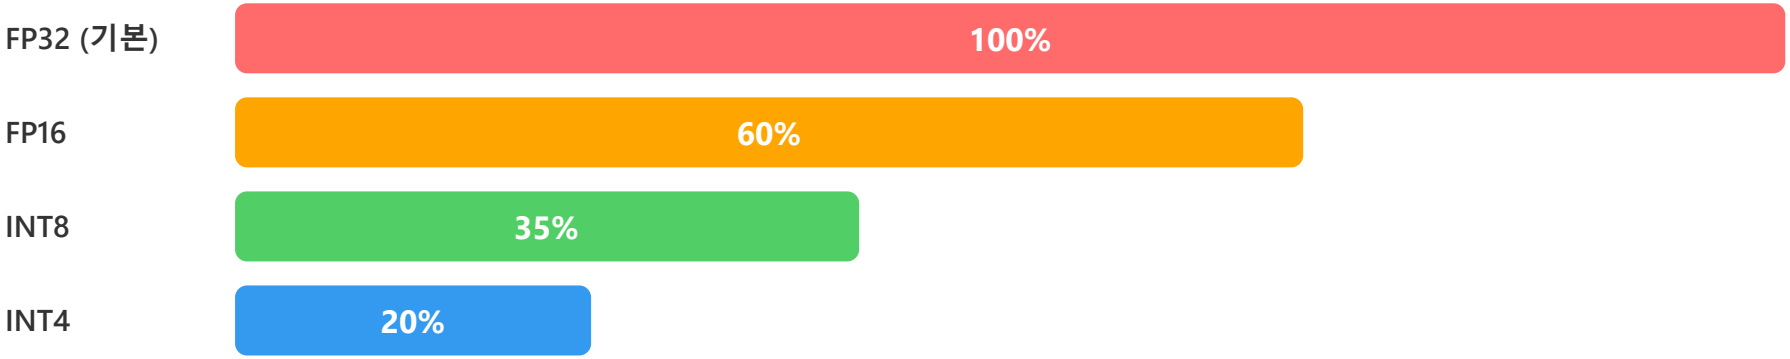

전력 절감 전략

1. **적극적 양자화**
   INT8/INT4 사용으로 연산량 감소

2. **온디맨드 추론**
   필요할 때만 모델 실행 (이벤트 기반)

3. **배치 처리**
   여러 샘플 모아서 한 번에 처리

4 **하드웨어 가속기 활용**

NPU/DSP 사용 (CPU보다 효율적)

트레이드오프: 배터리 수명 vs 모델 성능/정확도
의료 응용에서는 안전성을 해치지 않는 선에서 최적화 필수

Model Serving on Edge

엣지 디바이스에서의 모델 서빙

압축된 모델을 효율적으로 배포하고 실행하기 위한 인프라

엣지 추론 프레임워크

TF

TensorFlow Lite

- Google 제공
- Android/iOS 지원
- 광범위한 하드웨어
- .tflite 포맷

ML

Core ML

- Apple 전용
- iOS/macOS 최적화
- Neural Engine 활용
- .mlmodel 포맷

ONNX

ONNX Runtime

- 크로스 플랫폼
- 다양한 백엔드
- 모델 최적화 도구
- .onnx 포맷

PyTorch Mobile

- PyTorch 기반
- Android/iOS
- 쉬운 변환
- .ptl 포맷

배포 파이프라인

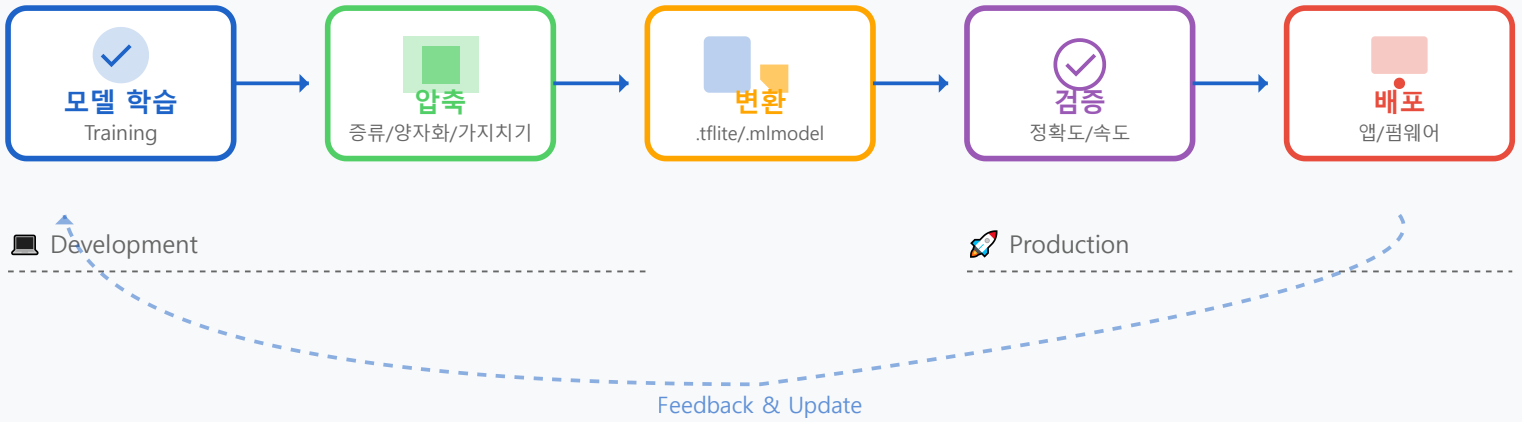

모범 사례

✓ 디바이스별 벤치마크 필수 (실제 하드웨어에서 테스트)

✓ OTA(Over-The-Air) 업데이트 지원

✓ Fallback 메커니즘 (클라우드 추론)

✓ 모니터링 및 로깅

Performance vs Size Tradeoffs

성능-크기 트레이드오프

압축 수준에 따른 모델 크기, 정확도, 속도의 균형점 찾기

파레토 최적 곡선 (Pareto Frontier)

Large Model

크기: 500MB
정확도: 95%
속도: 500ms

Medium Model

크기: 100MB
정확도: 93%
속도: 100ms

Small Model

크기: 20MB
정확도: 90%
속도: 20ms

Tiny Model

크기: 5MB
정확도: 85%
속도: 5ms

모델 선택 기준

클라우드 배포

Large/Medium 모델

정확도 최우선

모바일 앱

Medium/Small 모델

균형잡힌 성능

웨어러블

Small/Tiny 모델

크기 최소화

의사결정 가이드:

1. 최소 허용 정확도 결정
2. 목표 디바이스의 제약 조건 파악
3. 파레토 곡선 상에서 최적점 선택

Accuracy Preservation

정확도 유지 (Accuracy Preservation)

압축 과정에서 모델 성능을 최대한 보존하는 방법

압축률에 따른 정확도 변화

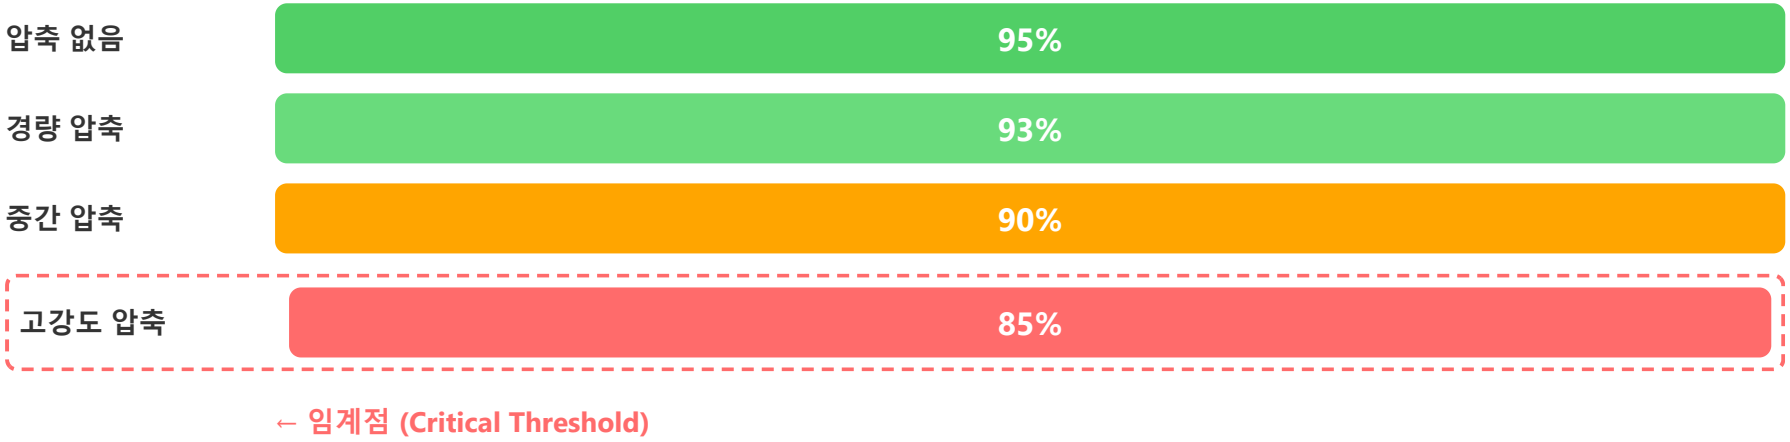

정확도 유지 전략

1. **Quantization-Aware Training (QAT)**
   학습 중 양자화 시뮬레이션 → 정확도 손실 최소화

2. **Fine-tuning after Compression**
   압축 후 재학습으로 성능 회복

3 **Sensitivity Analysis**

레이어별 민감도 분석 후 선택적 압축

4 **Knowledge Distillation**

Teacher 지식 활용으로 정확도 보존

⚠ **의료 AI 특수 고려사항:**

정확도 하락이 환자 안전에 직결 → 엄격한 임계값 설정 필수

FDA/CE 승인 기준 충족 여부 확인

Case Study: Mobile Diagnostics

사례 연구: 모바일 피부암 진단 앱

딥러닝 모델 압축을 통한 실시간 모바일 진단 시스템 구현

문제 정의

🎯 **목표:** 피부 병변 사진으로 양성/악성 분류

📱 **플랫폼:** iOS/Android 모바일 앱

⚡ **요구사항:** 3초 이내 결과, 오프라인 동작

압축 접근법

Step 1: Base Model

ResNet-50 (98MB, FP32)
정확도: 94.5%
추론: 2.5초

↓

Step 2: Knowledge Distillation

MobileNetV3 Student
크기: 24MB

정확도: 93.2%

↓

Step 3: INT8 Quantization

크기: 6MB (75% 감소)

정확도: 92.8%

추론: 0.8초

↓

Final: TFLite Optimization

최종 크기: 5.2MB

정확도: 92.5%

추론: 0.6초 ✅

최종 결과

94.7%	76%	-2.0%
크기 감소	속도 향상	정확도 변화

Hands-on: Model Compression

실습: 모델 압축 파이프라인

PyTorch를 이용한 Knowledge Distillation 및 Quantization 실습

1. Knowledge Distillation 코드

```
# Teacher-Student 증류 손실
def distillation_loss(student_logits, teacher_logits, labels, T=3):
    # Soft targets
    soft_loss = nn.KLDivLoss()(F.log_softmax(student_logits/T, dim=1),
                               F.softmax(teacher_logits/T, dim=1)) * T*T
    # Hard targets
    hard_loss = nn.CrossEntropyLoss()(student_logits, labels)
    return 0.7 * soft_loss + 0.3 * hard_loss
```

2. INT8 Quantization 코드

```
import torch.quantization

# 정적 양자화
model.qconfig = torch.quantization.get_default_qconfig('qnnpack')
model_prepared = torch.quantization.prepare(model)
# 캘리브레이션
model_prepared(calibration_data)
# 양자화 적용
model_quantized = torch.quantization.convert(model_prepared)
```

유용한 도구 및 라이브러리

PyTorch

torch.quantization
torch.nn.utils.prune

TensorFlow

TF-MOT (Model Optimization)
Quantization-Aware Training

ONNX

onnxruntime
Cross-framework

Hugging Face

Optimum
Transformer 최적화

실습 과제:

CIFAR-10 데이터셋으로 ResNet 모델 압축해보기
(증류 + 양자화 파이프라인 구현)

Deployment Strategies

배포 전략 및 체크리스트

압축 모델의 성공적인 프로덕션 배포를 위한 전략

배포 워크플로우

개발
- 모델 압축
- 로컬 테스트
- 벤치마킹

→

검증
- A/B 테스트
- 임상 검증
- 규제 승인

→

배포
- 점진적 출시
- 모니터링
- 피드백 수집

→

유지보수
- 성능 추적
- 모델 업데이트
- 버전 관리

배포 전 체크리스트 ✅

성능

- □ 정확도 목표 달성
- □ 지연시간 요구사항 충족
- □ 메모리 제약 내

안정성

- □ Edge case 테스트
- □ 에러 핸들링
- □ Fallback 메커니즘

규제

- □ FDA/CE 인증 (필요시)
- □ 개인정보 보호
- □ 설명 가능성

운영

- □ 로깅/모니터링
- □ OTA 업데이트
- □ 사용자 교육

플랫폼별 권장 전략

플랫폼	압축 방법	프레임워크
iOS	증류 + INT8	Core ML
Android	증류 + INT8	TF Lite
Web	경량 압축	TensorFlow.js
Embedded	INT4 + 가지치기	TF Lite Micro

Thank You

강의 요약

Part 1

Knowledge Distillation

- Teacher-Student 프레임워크
- Soft targets & Temperature
- Feature/Attention 전달

Part 2

Quantization & Pruning

- INT8/INT4 양자화
- 구조적/비구조적 가지치기
- 동적 희소성

Part 3

Edge Deployment

- 모바일/웨어러블 최적화
- POC 시스템
- 성능-크기 트레이드오프

핵심 베스트 프랙티스

✓ 압축 전 정확도 목표 및 제약사항 명확히 정의

✓ 여러 압축 기법 조합으로 시너지 효과

✓ 실제 디바이스에서 벤치마크 필수

✓ 의료 AI는 정확도 하락에 특히 민감 - 임상 검증 필수

✓ 배포 후 지속적 모니터링 및 업데이트

추천 도구 모음

압축: PyTorch Quantization, TensorFlow Model Optimization

변환: ONNX, TensorFlow Lite, Core ML Tools

추론: TensorRT, ONNX Runtime, TFLite

벤치마킹: MLPerf Mobile, AI Benchmark

Thank You!

Lecture 12: Knowledge Distillation and Model Compression

Questions? Contact via course forum or office hours