Model Serving on Edge

엣지 디바이스에서의 모델 서빙

압축된 모델을 효율적으로 배포하고 실행하기 위한 인프라

엣지 추론 프레임워크

TF

TensorFlow Lite

- Google 제공
- Android/iOS 지원
- 광범위한 하드웨어
- .tflite 포맷

ML

Core ML

- Apple 전용
- iOS/macOS 최적화
- Neural Engine 활용
- .mlmodel 포맷

ONNX

ONNX Runtime

- 크로스 플랫폼
- 다양한 백엔드
- 모델 최적화 도구
- .onnx 포맷

PyTorch Mobile

- PyTorch 기반
- Android/iOS
- 쉬운 변환
- .ptl 포맷

배포 파이프라인

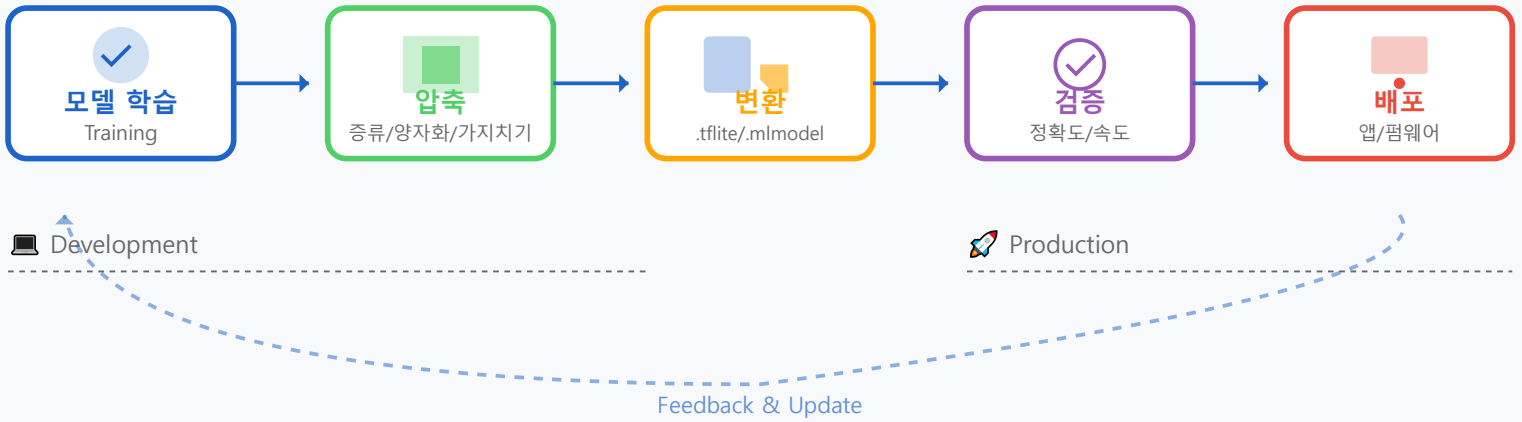

모범 사례

✓ 디바이스별 벤치마크 필수 (실제 하드웨어에서 테스트)

✓ OTA(Over-The-Air) 업데이트 지원

✓ Fallback 메커니즘 (클라우드 추론)

✓ 모니터링 및 로깅